

Relatório do Projeto Final

Ilie Cosmin Iftime, nº 112779
Inês Rodrigues da Cruz, nº 123557
Sofia Feliciano Quintino, nº123554

Big Data
Docente: Paulo Vieira

Licenciatura Tecnologias Digitais e Inteligência Artificial

1º Semestre 2025/2026

Introdução

Contextualização do problema

A mobilidade urbana constitui um dos principais desafios das cidades contemporâneas, influenciando diretamente a qualidade de vida dos cidadãos, a eficiência dos sistemas de transporte e a sustentabilidade ambiental. O crescimento da urbanização e o aumento da utilização do transporte individual tem contribuído para níveis elevados de congestionamento, especialmente nos centros urbanos, tornando cada vez mais necessária a adoção de soluções baseadas em dados que permitam compreender e mitigar estes fenómenos.

Paralelamente, os sistemas de mobilidade suave, como as bicicletas partilhadas, assumem um papel crescente no ecossistema urbano, promovendo alternativas mais sustentáveis ao transporte rodoviário tradicional. No entanto, a eficácia destes sistemas depende fortemente de uma gestão eficiente da disponibilidade de recursos, nomeadamente da distribuição equilibrada de bicicletas pelas diferentes estações, de forma a responder adequadamente à procura ao longo do tempo e do espaço.

Neste contexto, a cidade de Lisboa apresenta-se como um caso de estudo relevante, conjugando um sistema de bicicletas partilhadas em expansão — o sistema GIRA — com desafios persistentes ao nível do congestionamento de tráfego. A análise integrada destes dois fenómenos oferece uma oportunidade para explorar como os dados podem apoiar uma gestão mais eficiente da mobilidade urbana.

Objetivos

O principal objetivo deste projeto é enfrentar os desafios associados à mobilidade urbana na cidade de Lisboa, recorrendo a tecnologias de Big Data e Machine Learning, com o intuito de apoiar a tomada de decisão baseada em dados.

De forma mais específica, pretende-se:

- Recolher, integrar e preparar conjuntos de dados relacionados com a mobilidade urbana, nomeadamente dados de disponibilidade de bicicletas do sistema GIRA e dados de condicionamentos de trânsito;
- Identificar padrões temporais e espaciais relevantes, como variações na disponibilidade de bicicletas ao longo do dia e da semana, bem como diferenças de comportamento entre zonas da cidade;
- Desenvolver modelos analíticos e preditivos que permitam estimar a disponibilidade futura de bicicletas nas estações;
- Aplicar técnicas de *Machine Learning*, incluindo modelos de regressão e *clustering*, para identificar zonas com maior probabilidade de disponibilidade e hotspots de congestionamento;
- Criar visualizações claras e informativas que facilitem a interpretação dos resultados;
- Simular um cenário de utilização prática através de uma pipeline de inferência capaz de gerar recomendações em tempo quase real.

Metodologia

O projeto baseia-se em dois conjuntos de dados principais, armazenados numa base de dados MongoDB Atlas: dados de disponibilidade das estações do sistema GIRA e dados de condicionamentos de trânsito na cidade de Lisboa.


Os dados foram carregados para PySpark sob a forma de DataFrames e sujeitos a um processo rigoroso de limpeza e transformação. Esta etapa incluiu a conversão de campos temporais para o tipo *timestamp*, a normalização de texto, a extração de coordenadas geográficas e a remoção de valores inválidos ou incompletos.

Após a limpeza, os dados foram agregados a nível diário, permitindo integrar a média de bicicletas disponíveis com o número de condicionamentos de trânsito através de um *inner join*. Esta integração constituiu a base para a análise exploratória e para a modelação subsequente.

Análise de Resultados

A Análise Exploratória de Dados revelou padrões relevantes na mobilidade urbana de Lisboa. A evolução temporal mostrou que os condicionamentos de trânsito são mais frequentes durante os dias úteis, refletindo os fluxos pendulares típicos da cidade. A disponibilidade média de bicicletas apresenta variações mais suaves, sugerindo uma gestão relativamente estável, embora sujeita a fatores externos.

A análise por estação evidenciou assimetrias significativas na disponibilidade de bicicletas, com algumas estações sistematicamente mais cheias ou mais vazias. O histograma da disponibilidade revelou que o sistema opera frequentemente nos extremos, com muitas estações vazias ou próximas da capacidade máxima, indicando desequilíbrios logísticos.



A matriz de correlação revelou uma correlação negativa fraca entre a disponibilidade média de bicicletas e o número de condicionamentos de trânsito, sugerindo que ambos os fenómenos são influenciados por fatores externos comuns.


Matriz de Correlação




A análise geoespacial, através de mapas interativos, permitiu identificar hotspots de congestionamento bem definidos, concentrados sobretudo em zonas centrais, com maior incidência durante as horas de ponta.

Implementação Técnica

Ao nível da modelação, foram testadas diferentes abordagens de *Machine Learning*. A Regressão Linear foi utilizada como *baseline*, apresentando uma capacidade explicativa limitada ($R^2 \approx 0.48$), o que confirmou a sua inadequação para capturar a complexidade e a não linearidade dos padrões presentes nos dados.



Em comparação, o Random Forest Regressor revelou um desempenho significativamente superior à baseline, demonstrando capacidade para modelar relações não lineares e interações entre variáveis. No entanto, apesar desta melhoria clara, o Random Forest apresentou resultados inferiores quando comparado com outros modelos mais avançados testados ao longo do projeto, não sendo o modelo com melhor desempenho global.




O fator determinante para o sucesso dos modelos de alta performance foi a introdução de features de janela móvel, nomeadamente o número de bicicletas no registo anterior, a média da última hora e a tendência face a essa média. Estas variáveis permitiram capturar a dinâmica temporal do sistema, fornecendo contexto histórico recente que se revelou crucial para a qualidade das previsões.

Com base nesta engenharia de features avançada, o modelo XGBoost (Extreme Gradient Boosting) destacou-se como o mais eficaz entre todos os modelos avaliados, alcançando um desempenho excecional, com $R^2 = 0.99$ e RMSE = 0.48. Estes resultados indicam que o modelo explica cerca de 99% da variabilidade na disponibilidade de bicicletas, com um erro médio inferior a meia bicicleta por estação, representando um nível de precisão de grau operacional.

--- Tabela Comparativa de Resultados ---


	Modelo	RMSE	R^2
0	Random Forest	5.359743	0.334262
1	Linear Regression	4.718925	0.483938



```
--- Resultados do Modelo de Alta Performance ---  
RMSE = 0.48  
R2 = 0.99
```

Paralelamente, foi aplicado o algoritmo KMeans, que segmentou mais de 13 mil registos de trânsito em 10 clusters espaço-temporais, permitindo identificar hotspots de congestionamento com diferentes níveis de criticidade. A utilização de Análise de Componentes Principais (PCA) permitiu validar visualmente a separação dos clusters, confirmando a qualidade da segmentação obtida.

O projeto culmina numa pipeline de inferência, que simula consultas em tempo quase real, prevendo a disponibilidade de bicicletas em toda a cidade e recomendando zonas com maior probabilidade de oferta. Os resultados são apresentados através de um mapa interativo, tornando a informação clara, intuitiva e diretamente utilizável no contexto da mobilidade urbana.



Conclusões e Trabalho Futuro

Este projeto demonstrou com sucesso a construção de uma pipeline de Big Data de ponta a ponta, aplicada à mobilidade urbana em Lisboa. Foi possível transformar dados brutos em conhecimento válido, com impacto direto na experiência do utilizador.

O modelo preditivo desenvolvido revelou um nível de precisão excecional, validando a importância da engenharia de features temporais em problemas de séries temporais. A identificação de hotspots de congestionamento e de desequilíbrios na distribuição de bicicletas fornece informação valiosa para o planeamento urbano.

Como trabalho futuro, sugere-se a disponibilização do modelo através de uma API, a integração de dados externos (meteorologia, feriados, eventos) e a utilização das previsões como base para algoritmos de otimização de rotas das equipas de redistribuição da GIRA, maximizando o impacto prático da solução.

Apêndice Técnico

O projeto recorreu ao MongoDB como base de dados NoSQL orientada a documentos, ideal para o armazenamento de dados semi-estruturados, e ao PySpark como motor de processamento distribuído.

Foram utilizadas técnicas e componentes como: VectorAssembler, StringIndexer e Pipeline; Modelos de *Machine Learning* como RandomForestRegressor, LinearRegression e KMeans; *Window Functions* para criação de features temporais; Visualizações interativas com Plotly.

A combinação MongoDB + PySpark revelou-se uma arquitetura escalável e adequada ao processamento de Big Data em contextos urbanos.

Datasets

Bicicletas GIRA – Disponibilidade em Tempo Real

<https://dados.cm-lisboa.pt/dataset/gira-bicicletas-de-lisboa-historico/resource/e1388632-c8e7-4acf-8ddc-c654d66e5b42>

Condicionamentos de Trânsito – Lisboa

<https://dados.cm-lisboa.pt/dataset/condicionamentos-de-transito>